

บทที่ 7

การเรียนรู้แบบเบย์ (Bayesian Learning)

วัตถุประสงค์การเรียนรู้


1. เพื่อให้ทราบถึงนิยามของทฤษฎีของเบย์
2. เพื่อให้เข้าใจหลักการทำงานของการทำงานการจำแนกประเภทโดยใช้ทฤษฎีของเบย์
3. เพื่อให้เข้าใจหลักการทำงานของตัวจำแนกประเภทแบบเบย์อย่างง่ายและเครือข่ายงานแบบเบย์

การเรียนรู้แบบเบย์ (Bayesian Learning) เป็นการจำแนกประเภทรูปแบบหนึ่งที่อาศัยหลักการของความน่าจะเป็นเข้ามาช่วยในการหาคำตอบของประเภทตัวอย่างใหม่ ในบทนี้จะกล่าวถึงกฎของเบย์ที่นำมาใช้ทั้งในการเรียนรู้แบบเบย์อย่างง่าย (Naïve Bayesian) และ เครือข่ายงานแบบเบย์ (Bayesian Network) ดังรายละเอียดต่อไปนี้

7.1 ทฤษฎีของเบย์ (Bayes' theorem)

ทฤษฎีของเบย์ (Bayes' Theorem) ถูกพัฒนาขึ้นโดย Thomas Bayes โดยใช้หลักการของความน่าจะเป็นแบบมีเงื่อนไขมาพัฒนาเป็นทฤษฎีบทดังกล่าว โดยมีรายละเอียดดังต่อไปนี้

ถ้าให้เอกภพสัมพัทธ์ U ประกอบด้วยเหตุการณ์ที่ไม่สามารถเกิดขึ้นได้พร้อมกัน จำนวน k เหตุการณ์คือ $A_1, A_2, A_3, \dots, A_k$ ดังรูปที่ 7.1 และให้ E เป็นเหตุการณ์หนึ่งในปริภูมิตัวอย่างที่เกิดจากการทดลองเดียวกันนี้และต้องเป็นส่วนหนึ่งของ A_i ($i = 1, 2, 3, \dots, k$) จะสามารถคำนวณความน่าจะเป็นแบบมีเงื่อนไขของเหตุการณ์หนึ่งใน A_i เมื่อเหตุการณ์ E เกิดขึ้นแล้วได้ดังสมการที่ (7.1)



รูปที่ 7.1 เหตุการณ์ E บนเหตุการณ์ k เหตุการณ์ที่เกิดพร้อมกันไม่ได้

$$P(A_i / E) = \frac{P(E / A_i) \cdot P(A_i)}{\sum_{i=1}^k P(E / A_i) \cdot P(A_i)} = \frac{P(E / A_i) \cdot P(A_i)}{P(E)} \quad (7.1)$$

7.2 การเรียนรู้แบบเบย์ (Bayesian Learning)

การเรียนรู้แบบเบย์ เป็นเทคนิคที่ใช้ทฤษฎีความน่าจะเป็น ตามกฎของเบย์ (Bayes' Theorem) เพื่อหาว่าสมมติฐานใดน่าจะถูกต้องที่สุด โดยใช้ความรู้ก่อนหน้า (Prior Knowledge) ได้แก่ ความน่าจะเป็นก่อนหน้าสำหรับสมมติฐานหนึ่ง ๆ ร่วมกับข้อมูล เช่น ความน่าจะเป็นที่สังเกตได้สำหรับสมมติฐานหนึ่ง ๆ เพื่อหาสมมติฐานที่ดีที่สุด

การเรียนรู้แบบเบย์อาศัยหลักการของการคำนวณความน่าจะเป็นของแต่ละสมมติฐาน (ในที่นี้คือคลาสเป้าหมายหรือผลลัพธ์การทำนาย) โดยการเรียนรู้แบบเบย์เป็นการเรียนรู้เพิ่มเติม เนื่องจากตัวอย่างใหม่ที่ได้มาถูกนำมาปรับเปลี่ยนการแจกแจงซึ่งมีผลต่อการเพิ่ม หรือ ลดความน่าจะเป็น ทำให้มีการเรียนรู้ที่เปลี่ยนไป วิธีการนี้ตัวแบบจะถูกปรับเปลี่ยนไปตามตัวอย่างใหม่ที่ได้โดยผนวกกับความรู้เดิมที่มี ซึ่งการทำนายค่าคลาสเป้าหมายของตัวอย่างใช้ความน่าจะเป็นมากที่สุดของทุกสมมติฐาน

จากทฤษฎีของเบย์ เราสามารถคำนวณความน่าจะเป็นของสมมติฐานต่าง ๆ โดยใช้สมการที่ 7.2

$$P(h|D) = \frac{P(D|h) * P(h)}{P(D)} \quad (7.2)$$

โดย

- D แทนข้อมูลที่นำมาใช้ในการคำนวณการแจกแจงความน่าจะเป็น posteriori probability ของสมมติฐาน h คือ $P(h|D)$ ตามทฤษฎี
- $P(h)$ คือ ความน่าจะเป็นก่อนหน้าของสมมติฐาน h
- $P(D)$ คือ ความน่าจะเป็นก่อนหน้าของชุดข้อมูลตัวอย่าง D
- $P(h|D)$ คือ ความน่าจะเป็นของ h เมื่อรู้ D
- $P(D|h)$ คือ ความน่าจะเป็นของ D เมื่อรู้ h

ตัวอย่างการคำนวณเพื่อเลือกสมมติฐานโดยกฎของเบย์

คนไข้คนหนึ่งไปตรวจหา โรคมะเร็ง ผลการตรวจเป็นบวก (+) อยากทราบว่า เราควรวินิจฉัยโรคคนไข้คนนี้เป็นโรคมะเร็งจริงหรือไม่ โดยมีข้อมูลความเป็นจริง ดังนี้

- ผลการตรวจเมื่อเป็นบวกจะให้ความถูกต้อง 98% กรณีที่มีโรคนั้นอยู่จริง
- ผลการตรวจเมื่อเป็นลบจะให้ความถูกต้อง 97% กรณีที่ไม่มีโรคนั้น
- 0.008 ของประชากรทั้งหมดเป็นโรคมะเร็ง

จากความน่าจะเป็นข้างต้น เราจะทราบว่าการน่าจะเป็นต่อไปนี้

$$\begin{aligned} P(\text{cancer}) &= 0.008 & P(\sim\text{cancer}) &= 0.992 \\ P(+ | \text{cancer}) &= 0.98 & P(- | \text{cancer}) &= 0.02 \\ P(+ | \sim\text{cancer}) &= 0.03 & P(- | \sim\text{cancer}) &= 0.97 \end{aligned}$$

เราสามารถคำนวณค่าความน่าจะเป็นของสมมติฐานว่าคนไข้เป็น หรือไม่เป็นโรคมะเร็ง เมื่อทราบผลตรวจเป็นบวก โดยใช้กฎของเบย์ ดังนี้

สมมติฐานที่ 1 คนไข้เป็นโรคมะเร็งจริงเมื่อมีผลการตรวจเป็นบวก

เขียนแทนด้วย $P(\text{cancer} | +)$

แทนค่าในสูตร

$$\begin{aligned} P(\text{cancer} | +) &= \frac{P(+ | \text{cancer})P(\text{cancer})}{P(+)} \\ &= 0.98 \times 0.008 \\ &= 0.0078 \end{aligned}$$

สมมติฐานที่ 2 คนไข้เป็นไม่เป็นโรคมะเร็งจริงเมื่อมีผลการตรวจเป็นบวก

เขียนแทนด้วย $P(\sim\text{cancer} | +)$

แทนค่าในสูตร

$$\begin{aligned} P(\sim\text{cancer} | +) &= \frac{P(+ | \sim\text{cancer})P(\sim\text{cancer})}{P(+)} \\ &= 0.03 \times 0.992 \\ &= 0.0298 \end{aligned}$$

เนื่องจากผลรวมของ $P(\text{cancer} | +)$ กับ $P(\sim\text{cancer} | +)$ เท่ากับ 1 เราสามารถ Normalize ค่าของ $P(\text{cancer} | +) = 0.0078 / (0.0078 + 0.0298) = 0.21$ และ $P(\sim\text{cancer} | +) = 0.0298 / (0.0078 + 0.0298) = 0.79$

สรุปว่า สมมติฐานที่ 1 มีค่าความน่าจะเป็นเท่ากับ 0.21 และสมมติฐานที่ 2 มีค่าความน่าจะเป็นเท่ากับ 0.79 ในการเลือกตอบสมมติฐานเนื่องจากสมมติฐานที่ 2 มีค่ามากกว่า สมมติฐานที่ว่าคนไข้ไม่เป็นโรคมะเร็งเมื่อทราบผลตรวจเป็นบวก ด้วยความน่าจะเป็น 0.79 จึงถูกเลือก

7.3 ตัวจำแนกประเภทที่ดีที่สุดแบบเบย์ (Bayes Optimal Classification)

ในการจำแนกประเภทตัวอย่าง X ใด ๆ ที่น่าจะเป็นที่สุด ของกรณีที่เกิดการจำแนกประเภทตัวอย่างมีความแตกต่างจากสมมติฐาน ที่ต่างกัน เราจะใช้ตัวจำแนกประเภทที่ดีที่สุดแบบเบย์ เพื่อจำแนกประเภทตัวอย่าง X ที่น่าจะเป็นที่สุด

กำหนดให้

- h_{MAP} (Maximum A Posterior Hypothesis) แทน สมมติฐานที่น่าจะเป็นที่สุด
- ถ้า h_{MAP} เป็นสมมติฐานที่น่าจะเป็นที่สุด h_{MAP} อาจไม่เป็นการจำแนกประเภทที่ว่องไวที่น่าจะเป็นที่สุด (most probable classification)
- นิยามตัวจำแนกประเภทที่ดีที่สุดแบบเบย์

$$h_{\text{MAP}}(x) = \underset{v_j \in V}{\operatorname{argmax}} \sum_{h_j \in H} P(v_j|h_j)P(h_j|D) \quad (7.3)$$

อธิบายได้โดย พิจารณสมมติฐานทั้งสามต่อไปนี้

$$P(h_1|D) = 0.4 \quad P(h_2|D) = 0.3 \quad P(h_3|D) = 0.3$$

เมื่อให้ตัวอย่าง X ผลการจำแนกประเภทของสมมติฐานเป็นดังนี้

$$h_1(X) = + \quad h_2(X) = - \quad h_3(X) = -$$

จากตัวอย่างข้างต้น เราทราบว่า

$$P(h_1|D) = 0.4 \quad P(-|h_1) = 0 \quad P(+|h_1) = 1$$

$$P(h_2|D) = 0.3 \quad P(-|h_2) = 1 \quad P(+|h_2) = 0$$

$$P(h_3|D) = 0.3 \quad P(-|h_3) = 1 \quad P(+|h_3) = 0$$

จะได้ว่า
$$\sum_{h_i \in H} P(+|h_i)P(h_i|D) = 0.4$$

$$\sum_{h_i \in H} P(-|h_i)P(h_i|D) = 0.6$$

ดังนั้น การจำแนกประเภทตัวอย่าง X ที่มี MAP Class คือคลาสที่น่าจะเป็นมากที่สุด คือ -

7.4 วิธีการเรียนรู้แบบง่าย (Naïve Bayesian Learning)

ตัวจำแนกแบบเบย์อย่างง่าย (Naive Bayesian Classifier) คือโมเดลการจำแนกประเภทข้อมูลที่ใช้หลักความน่าจะเป็นซึ่งอยู่บนพื้นฐานของ Bayes' Theorem และสมมติฐาน ที่ให้การเกิดของเหตุการณ์ต่างๆเป็นอิสระต่อกัน (Independence)

กำหนดให้ $P(h)$ ความน่าจะเป็นที่จะเกิดเหตุการณ์ h และ $P(h|D)$ คือความน่าจะเป็นที่จะเกิดเหตุการณ์ h เมื่อเกิดเหตุการณ์ D จากตัวแปรที่กำหนดและแนวคิดของ Bayes' Theorem นั้นเราสามารถทำนายเหตุการณ์ที่พิจารณาได้จากการเกิดของเหตุการณ์ต่างๆ ได้ดังสมการ

$$P(h|D) = [P(D|h) * P(h)]/P(D)$$

7.4.1 การสร้างสมการการทำนาย

เมื่อเกิดเหตุการณ์ลมแรงจะสามารถทำนายการไปเล่นเทนนิสได้ดังสมการต่อไปนี้

$$P(\text{การไปเล่นเทนนิส} | \text{ลมแรง}) = P(\text{ลมแรง} | \text{การไปเล่นเทนนิส}) \times P(\text{การไปเล่นเทนนิส})/P(\text{ลมแรง})$$

จากตัวอย่างที่กล่าวมานั้น เราสามารถทำนาย การไปเล่นเทนนิส โดยสังเกตอุณหภูมิ อย่างไรก็ดี ตามเหตุการณ์ที่นำมาใช้ในการทำนายนั้นต้องสอดคล้องกับเหตุการณ์ที่จะทำนาย เช่น ถ้าหากเรา ต้องการทำนายการไปเล่นเทนนิส เราก็จะไม่ใช้เหตุการณ์ฝนตกมาพิจารณา เพราะเหตุการณ์ทั้งสองไม่มีความเกี่ยวข้องกัน

เมื่อพิจารณา ทฤษฎีของเบย์ และคุณสมบัติเป็นอิสระต่อกันที่กล่าวมาในตอนต้น จะสามารถ แสดงการคัดแยกประเภทข้อมูล ที่มีเหตุการณ์ (E) มากกว่า 1 เหตุการณ์ ได้ดังสมการต่อไปนี้

$$P(h|E_1, E_2, \dots, E_n) = \frac{P(E_1|h) \times P(E_2|h) \times \dots \times P(E_n|h) \times P(h)}{P(E_1, E_2, \dots, E_n)} \quad (7.4)$$

ในการคัดแยกประเภทข้อมูลสำหรับเหตุการณ์ใด ๆ นั้น ขึ้นอยู่กับค่า $P(h|E_1, E_2, \dots, E_n)$ โดยจะ จัดอยู่ในประเภทใด ๆ เมื่อทำให้ $P(h|E_1, E_2, \dots, E_n)$ มีค่าสูงสุด เมื่อพิจารณาถึงค่าสูงสุดดังนั้นก็จึงสามารถ ตัดพจน์ $P(E_1, E_2, \dots, E_n)$ ออกจากการพิจารณาเพราะเป็นค่าคงที่ จึงได้สมการของการหา MAP class ของตัวจำแนกประเภทแบบเบย์อย่างง่ายดังสมการที่ (7.5)

$$\text{argmax}\{P(h|E_1, E_2, \dots, E_n)\} \quad (7.5)$$

7.4.2 ตัวจำแนกประเภทแบบเบย์อย่างง่าย (Naïve Bayes Classifier)

จากการนิยามข้างต้นเราสามารถสร้างตัวจำแนกประเภทแบบเบย์อย่างง่ายได้ดังต่อไปนี้

Assume target function $f : X \rightarrow V$, where each instance x described by attributes $\langle a_1, a_2 \dots a_n \rangle$. Most probable value of $f(x)$ is:

$$\begin{aligned} v_{MAP} &= \text{argmax}_{v_j \in V} P(v_j | a_1, a_2 \dots a_n) \\ v_{MAP} &= \text{argmax}_{v_j \in V} \frac{P(a_1, a_2 \dots a_n | v_j) P(v_j)}{P(a_1, a_2 \dots a_n)} \\ &= \text{argmax}_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) \end{aligned}$$

Naive Bayes assumption:

$$P(a_1, a_2 \dots a_n | v_j) = \prod_i P(a_i | v_j)$$

which gives

$$\text{Naive Bayes classifier: } v_{NB} = \text{argmax}_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$

รูปที่ 7.2 การนิยามของ Naïve Bayes Classifier (V_{NB})

จากรูปที่ 7.2 จะได้ว่าคำตอบซึ่งก็คือคลาสผลลัพธ์ v_i ใด ๆ ที่ถูกเลือก จะเป็นคลาสที่มีค่าความน่าจะเป็นมากที่สุด (MAP class) ที่ได้จากการคำนวณ และจะถูกใช้เป็นคำตอบให้แก่ตัวอย่างคำถามที่ต้องการ

7.4.3 การสร้างโมเดล และการนำตัวจำแนกประเภทแบบเบย์อย่างง่ายไปใช้งาน

ตัวอย่างดังต่อไปนี้ เป็นจำแนกหรือทำนายพฤติกรรมการออกไปเล่นเทนนิสด้วยค่าคลาสผลลัพธ์ 2 ค่า คือ ไปเล่น (P) หรือ ไม่去玩 (N) โดยดูจากข้อมูลที่เก็บไว้ในวันที่ผ่านๆ มา จำนวน 14 วัน ดังแสดงในตารางที่ 7.1

ตารางที่ 7.1 ข้อมูลการออกไปเล่นกีฬา

Outlook	Temperature	Humidity	Windy	Class
sunny	hot	high	false	N
sunny	hot	high	true	N
overcast	hot	high	false	P
rain	mild	high	false	P
rain	cool	normal	false	P
rain	cool	normal	true	N
overcast	cool	normal	true	P
sunny	mild	high	false	N
sunny	cool	normal	false	P
rain	mild	normal	false	P
sunny	mild	normal	true	P
overcast	mild	high	true	P
overcast	hot	normal	false	P
rain	mild	high	true	N

ตัวอย่าง กำหนดให้ตัวอย่างใหม่ (New instance) ที่ต้องการจำแนกประเภท คือ

$x = \langle \text{Sunny, Cool, High, True} \rangle$

จงทำนายว่าหากมีคุณสมบัติตาม x นักกีฬาคอนนั้นจะออกไปเล่นเทนนิสหรือไม่

วิธีการคำนวณ

เราสามารถแบ่งกลุ่มข้อมูลตามประเภทของ Class ได้ดังต่อไปนี้

Outlook	Temperature	Humidity	Windy	Class	
overcast	hot	high	false	P	9
rain	mild	high	false	P	
rain	cool	normal	false	P	
overcast	cool	normal	true	P	
sunny	cool	normal	false	P	
rain	mild	normal	false	P	
sunny	mild	normal	true	P	
overcast	mild	high	true	P	
overcast	hot	normal	false	P	
Outlook	Temperature	Humidity	Windy	Class	
sunny	hot	high	false	N	5
sunny	hot	high	true	N	
rain	cool	normal	true	N	
sunny	mild	high	false	N	
rain	mild	high	true	N	

ดังนั้นจึงได้ค่าของความน่าจะเป็นก่อนหน้า (Prior Probabilities) ดังนี้

$$P(P) = 9/14 = 0.64$$

$$P(N) = 5/14 = 0.36$$

และสามารถคำนวณความน่าจะเป็นของแต่ละคุณสมบัติ (Likelihood Probabilities) ได้ดังต่อไปนี้

Outlook

$P(\text{sunny} P) = 2/9$	$P(\text{sunny} N) = 3/5$
$P(\text{overcast} P) = 4/9$	$P(\text{overcast} N) = 0/5$
$P(\text{rain} P) = 3/9$	$P(\text{rain} N) = 2/5$

Temperature

$P(\text{hot} P) = 2/9$	$P(\text{hot} N) = 2/5$
$P(\text{mild} P) = 4/9$	$P(\text{mild} N) = 2/5$
$P(\text{cool} P) = 3/9$	$P(\text{cool} N) = 1/5$

Humidity

$P(\text{high} P) = 3/9$	$P(\text{high} N) = 4/5$
$P(\text{normal} P) = 6/9$	$P(\text{normal} N) = 1/5$

Windy

$P(\text{true} P) = 3/9$	$P(\text{true} N) = 3/5$
$P(\text{false} P) = 6/9$	$P(\text{false} N) = 2/5$

พิจารณาข้อมูลสภาพอากาศดังต่อไปนี้

< Outlook = sunny, Temp = cool, Hum = high, Wind = true >

ต้องการทำนายว่านักกีฬาที่เจอสภาพอากาศในรายละเอียดข้างต้น จะออกไปเล่นเทนนิสหรือไม่
คำนวณความน่าจะเป็นได้ดังนี้

จาก

$$v_{\text{MAP}} = \arg \max_{v_j \in \{\text{yes}, \text{no}\}} P(v_j) \prod_i P(a_i | v_j)$$

$$= \arg \max_{v_j \in \{\text{yes}, \text{no}\}} P(v_j) P(\text{Outlook} = \text{sunny} | v_j) P(\text{Temp} = \text{cool} | v_j) P(\text{Hum} = \text{high} | v_j) P(\text{Windy} = \text{true} | v_j)$$

แทนค่าในสมการ

$$\begin{aligned} & Pr(P) Pr(\text{sunny} | P) Pr(\text{cool} | P) Pr(\text{high} | P) Pr(\text{true} | P) \\ &= (9/14) * (2/9) * (3/9) * (3/9) * (3/9) = .0053 \end{aligned}$$

$$\begin{aligned} & Pr(N) Pr(\text{sunny} | N) Pr(\text{cool} | N) Pr(\text{high} | N) Pr(\text{true} | N) \\ &= (5/14) * (3/5) * (1/5) * (4/5) * (3/5) = .0206 \end{aligned}$$

จากผลการคำนวณสรุปได้ว่า ถ้าเจอสภาพอากาศ < Outlook = sunny, Temp = cool, Hum = high, Wind = true > แล้ว นักกีฬาก็จะไม่ไปเล่นเทนนิส (คลาส N) เนื่องจากให้ค่าสมมติฐานที่สูงกว่า คือ 0.0206

7.5 เครือข่ายงานแบบเบย์ (Bayesian Belief Networks)

เครือข่ายงานแบบเบย์ เป็นแบบจำลองกราฟของความน่าจะเป็น หรือเรียกอีกชื่อหนึ่งว่า

“Bayes net”


ซึ่งเป็นวิธีการเรียนรู้ที่ลดข้อจำกัดของเรียนรู้แบบเบย์อย่างง่ายในสมมุติฐานความไม่ขึ้นต่อกันระหว่างคุณสมบัติ โดย Bayesian network ใช้อธิบายความไม่ขึ้นต่อกันอย่างมีเงื่อนไข (Condition Independent) ระหว่างตัวแปร

7.5.1 เงื่อนไขของเครือข่ายงานแบบเบย์

- ความสัมพันธ์ของแต่ละโหนดจะไม่วนกลับมาหาโหนดเดิม

- แต่ละโหนดจะมีความสัมพันธ์กันตามทิศทางที่แบบจำลองนำเสนอ
- โหนดทั้งหมดใน Bayesian Network แต่ละโหนดจะแทนด้วยตัวแปรต่างๆที่เกี่ยวข้องกับเหตุการณ์หรือข้อมูลที่สนใจ
- การเชื่อมต่อระหว่างคู่โหนดด้วยลูกศร ถ้าลูกศรจากโหนด X ชี้ไปหาโหนด Y จะเรียกว่า โหนด X เป็นโหนดพ่อแม่(parents) ของ Y
- แต่ละโหนด X_i จะมีเงื่อนไขการกระจายความน่าจะเป็น $P(X_i | \text{parents}(X_i))$ ซึ่งส่งผลต่อโหนดพ่อแม่ของแต่ละโหนด

เครือข่ายงานแบบเบย์ ถูกนำมาอธิบายความไม่ขึ้นต่อกันอย่างมีเงื่อนไข จึงทำให้อาจมีบางโหนดไม่มีความสัมพันธ์ใดๆ กับโหนดที่เหลือก็ได้ แสดงดังรูปที่ 7.3



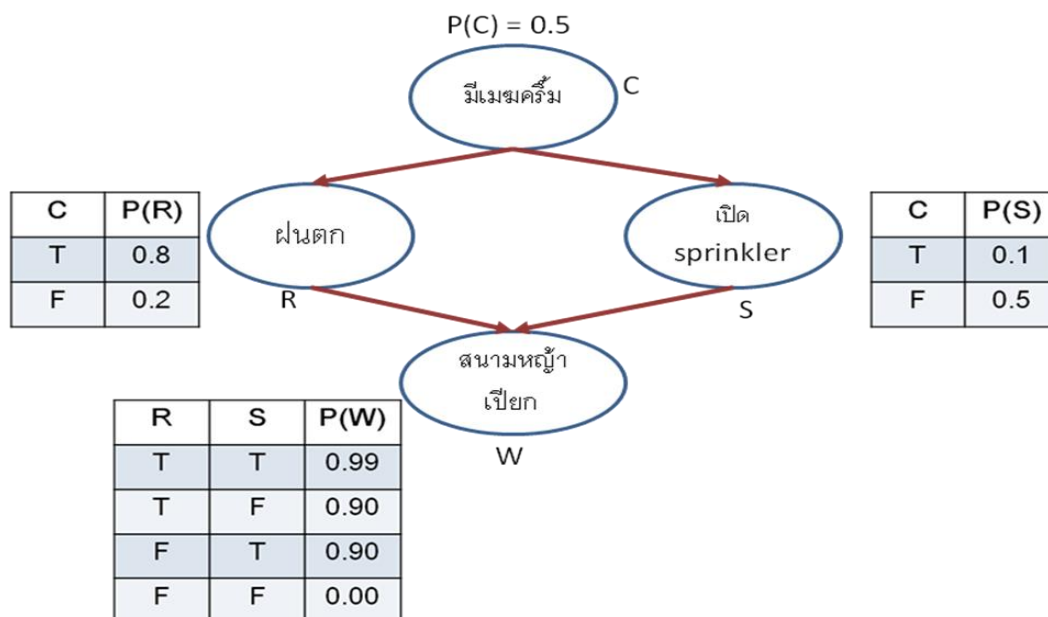
รูปที่ 7.3 เครือข่ายงานแบบเบย์ของเหตุการณ์วัสดุคาร์ทไม่ติด โดยมีรายละเอียดดังนี้

- ความไม่ขึ้นต่อกันอย่างมีเงื่อนไข (Condition Independent)
 X ไม่ขึ้นกับ Y อย่างมีเงื่อนไข คือ ความน่าจะเป็นของ X ไม่ขึ้นอยู่กับค่าของ Y เมื่อรู้ค่า Z นั่นคือ $P(X | Y, Z) = P(X | Z)$
- ความไม่ขึ้นต่อกันอย่างมีเงื่อนไข ทำให้การหาความน่าจะเป็นของตัวแปรที่ต้องการง่ายขึ้นโดยไม่ต้องสนใจตัวแปรอื่น เช่น
 - ฟาร์มิ่ง จะไม่ขึ้นกับ ฝนตก เสมอไป ถ้ารู้ว่าเกิดฟ้าแลบ
 - เนื่องจากเมื่อเกิด ฟ้าแลบ แล้วจะตามมาด้วย ฟาร์มิ่ง เสมอ
 - $P(\text{ฟาร์มิ่ง} | \text{ฝนตก}, \text{ฟ้าแลบ}) = P(\text{ฟาร์มิ่ง} | \text{ฟ้าแลบ})$
- ในเครือข่ายงานแบบเบย์ ตัวแปรแต่ละตัวจะมีความน่าจะเป็นเฉพาะ ที่อาจเป็นความน่าจะเป็นของโหนดเริ่มต้น หรือ ความน่าจะเป็นที่ได้จากความสัมพันธ์มากกว่าหนึ่งโหนด โดยความน่าจะเป็นที่มาจากตัวแปรมากกว่าหนึ่งตัวเรียกว่า “ความน่าจะเป็นร่วม” (Joint Probability)
- สมการของความน่าจะเป็นร่วมมีดังนี้

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{Parents}(X_i)) \quad (7.6)$$
 - $\text{Parents}(X_i)$ หมายถึง โหนดพ่อแม่โดยตรงของ X_i

7.5.2 ตัวอย่างเครื่องข่ายงานแบบเบย์

ตัวอย่างที่ 1



รูปที่ 7.4 เครือข่ายงานแบบเบย์ของเหตุการณ์สนามหญ้าเปียก

จากรูปที่ แสดง เครือข่ายงานแบบเบย์ ที่แสดงความน่าจะเป็นในการเกิดเหตุการณ์สนามเปียก จากข่ายงานข้างต้นจะมีการคำนวณตารางความน่าจะเป็นในแต่ละเงื่อนไข ที่เรียกว่าตาราง CPT (The Conditional Probability Table) ซึ่งใช้แสดงความขึ้นอยู่กับกันในตัวแปรที่เกี่ยวข้อง เช่น โอกาสที่สนามหญ้าเปียก (W) หากมีฝนตก (R=T) และ เปิด sprinkler (S=T) มีค่า 0.99 เป็นต้น

ตัวอย่างการคำนวณ


จากเครือข่ายงานแบบเบย์ ที่แสดงความน่าจะเป็นของสนามหญ้าเปียก จงหาความน่าจะเป็นที่สนามหญ้าจะเปียกเพราะฝนตก โดยที่ sprinkler ไม่ได้ทำงาน โดยสภาพของอากาศในตอนนั้นไม่มีเมฆครึ้ม

$$\begin{aligned}
 P(W, \sim S, R, \sim C) &= P(W | \sim S, R) P(\sim S | \sim C) P(R | \sim C) P(\sim C) \\
 &= 0.90 * 0.5 * 0.2 * 0.5 \\
 &= 0.0450
 \end{aligned}$$

ดังนั้นความน่าจะเป็นที่สนามหญ้าจะเปียกเพราะฝนตกโดยที่ sprinkler ไม่ได้ทำงานและอากาศไม่มีเมฆครึ้ม คือ 0.045 (4.5%)

ตัวอย่างที่ 2

รูปที่ 7.5 แสดงเครือข่ายงานแบบเบย์ ของเงื่อนไขการเกิดโรคต่าง ๆ ที่มีความเกี่ยวพันกัน ได้แก่ ประวัติครอบครัว (Family History:FS) เป็นคนสูบบุหรี่ (Smoker:S) เป็นมะเร็งถุงลม (LungCancer:LC) เป็นถุงลมโป่งพอง (Emphysema) มีผลการ X-Ray เป็นบวก (PositiveXRay:P) และ มีอาการหอบเหนื่อย (Dyspnea:D)



รูปที่ 7.5 แสดงเครือข่ายงานแบบเบย์ของเงื่อนไขการเกิดโรคต่าง ๆ

ซึ่งจากความรู้ก่อนหน้ามีข้อมูลปรากฏดังตาราง CPT ดังนี้

	(FH, S)	(FH, ~S)	(~FH, S)	(~FH, ~S)
LC	0.8	0.5	0.7	0.1
~LC	0.2	0.5	0.3	0.9

ตัวอย่างการคำนวณ

จงหาค่าความน่าจะเป็นที่ผู้ป่วยจะเป็นโรคมะเร็งปอด ในกรณีที่พบว่าประวัติคนในครอบครัวเป็นโรคมะเร็ง และเป็นคนที่สูบบุหรี่

$$\begin{aligned}
 P(\text{LC} = \text{yes}, \text{FH} = \text{yes}, \text{S} = \text{yes}) &= P(\text{LC}, \text{FH}, \text{S}) \\
 &= P(\text{FH}) * P(\text{S}) * P(\text{LC} | \text{FH}, \text{S}) \\
 &= P(\text{FH}) * P(\text{S}) * 0.8
 \end{aligned}$$

7.5.3 บทสรุปของเครือข่ายงานแบบเบย์

Bayesian network ยอมให้สับเซตของตัวแปรอิสระต่อกันอย่างมีเงื่อนไข โดยใช้รูปกราฟแสดงความเกี่ยวพันระหว่างตัวแปร มีที่จุดยอดคือ ตัวแปรและเส้นเชื่อมระหว่างจุดคือการไม่เป็นอิสระต่อกันของตัวแปรเหล่านั้น การกำหนดเครือข่ายงานแบบเบย์ จะมีผลต่อการคำนวณ กล่าวคือ

- ถ้าผู้ใช้กำหนดเครือข่ายทั้งหมด โปรแกรมเพียงคำนวณค่าเดิมในเครือข่าย
- ถ้าผู้ใช้กำหนดเครือข่ายบางส่วน โปรแกรมต้องมีการทดสอบการเป็นอิสระต่อกันของแต่ละส่วนในเครือข่าย
- ถ้าผู้ใช้ไม่กำหนดโครงสร้างเครือข่ายเลย โปรแกรมต้องทดลองทุกการจัดหมู่ที่เป็นไปได้ซึ่งใช้เวลาในการคำนวณนาน

สรุป

การจำแนกประเภทเป็น การศึกษาการแบ่งกลุ่มข้อมูล พบในสาขาวิชาทั้งทางด้านสถิติ เทคโนโลยีสารสนเทศ และการเรียนรู้ด้วยเครื่อง (Machine Learning) การใช้ความน่าจะเป็นในการจำแนกประเภทจะใช้ทฤษฎีของเบย์ ซึ่งถ้าตัวแปรเป็นอิสระต่อกัน เราใช้วิธีการเรียนรู้แบบเบย์อย่างง่าย (Naive Bayesian Learning) และในกรณีที่ตัวแปรไม่เป็นอิสระต่อกัน เราเลือกใช้วิธีเครือข่ายงานแบบเบย์ (Bayesian Network) โดยใช้ความน่าจะเป็นก่อนหน้ามาช่วยร่วมในการคำนวณ

แบบฝึกหัด

1. จงสรุปความแตกต่าง และประเภท งานที่เหมาะสมของตัวจำแนกประเภทแบบเบย์อย่างง่าย (Naïve Bayesian Classifier) และ เครือข่ายงานแบบเบย์ (Bayesian Belief Network)
2. จากตารางข้อมูลที่ 7.1 จงจำแนกประเภทของข้อมูลใหม่ที่มีคุณสมบัติดังต่อไปนี้
 - 2.1 $x = \langle \text{Overcast, Hot, High, True} \rangle$
 - 2.2 $x = \langle \text{Rainy, Mild, Normal, False} \rangle$
3. จากตัวอย่างที่ 1 ของเครือข่ายงานแบบเบย์ จงหาค่าความน่าจะเป็นที่ สุนัขหมาจะเปียก ในกรณีที่พบว่าไม่มีเมฆครึ้ม ฝนไม่ตก แต่เปิด sprinkler น้ำ